

# **Лекция 4: Байесовский классификатор**

Евгений Борисов


четверг, 11 октября 2018 г.

# Классификатор: с чего все начинается?

## *хорошие и плохие коты*

извлекаем признаки

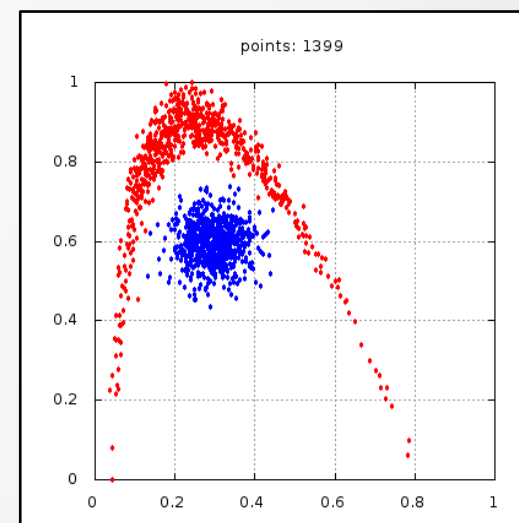
один кот — одна точка



→ [0.14, 12, ..., 345]




→ [78.0, 20, ..., 177]






# Классификатор

разделения объектов на классы

Детектор котов:



→ вектор-признак → есть/нет



# Классификатор: о задаче

разделение данных на части (классы)  
обучение «с учителем»

**Учебный набор:** [ объект, ответ ]

**Задача:** классификатор

*объект* → *вектор-признак* → *результат*

**Обучение:** минимизация ошибки

ошибка = результат - правильный ответ

**Критерий остановки:**

достигнут порог значения ошибки,  
и/или порог количества циклов

# Классификатор: данные

$$\begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \dots & x_n^{(1)} & y^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \dots & x_n^{(2)} & y^{(2)} \\ \vdots & \vdots & & \vdots & \vdots \\ x_1^{(m)} & x_2^{(m)} & \dots & x_n^{(m)} & y^{(m)} \end{bmatrix}$$

$x$  - вектор-признак

$y$  - метка класса

$n$  - размер пространства признаков

$m$  - количество примеров

# Байесовский классификатор

$X$  - объекты

$Y$  - ответы

$X \times Y$  - вероятностное пространство с плотностью  $p(x,y)$

$(x_i, y_i)$  - выборка

## **Задача:**

найти ф-цию (классификатор)

**$a: X \rightarrow Y$**  с минимальной ошибкой

# Байесовский классификатор

$X$  - объекты                       $Y$  - ответы

$X \times Y$  - вероятностное пространство с плотностью  $p(x,y)$

$(x_i, y_i)$  - выборка

## Задача:

найти ф-цию (классификатор)

**$a: X \rightarrow Y$**  с минимальной ошибкой

**принцип максимума апостериорной вероятности**

$$a(x) = \underset{y \in Y}{\operatorname{argmax}} P(y|x)$$

# Байесовский классификатор

**принцип максимума апостериорной вероятности**

$$a(x) = \underset{y \in Y}{\operatorname{argmax}} P(y|x) = \underset{y \in Y}{\operatorname{argmax}} P(y) p(x|y)$$

$P(y)$  - априорная вероятность класса  $y$

$p(x|y)$  - ф-ция правдоподобия класса  $y$

$P(y|x)$  - апостериорная вероятность класса  $y$

формула Байеса :

$$P(A|B) = \frac{P(A)P(B|A)}{P(B)}$$



# Байесовский классификатор

о функционале среднего риска:

**$a: X \rightarrow Y$**  - классификатор

**$A_y = \{ x \in X \mid a(x) = y \}$** ,  $y \in Y$  - разбиение  **$X$**  на части

**Ошибка:** объект  **$x$**  класса  **$y$**  попал в класс  **$s$**   
 **$A_s$ ,  $s \neq y$**

# Байесовский классификатор

о функционале среднего риска:

$a: X \rightarrow Y$  - классификатор

$A_y = \{ x \in X \mid a(x) = y \}$ ,  $y \in Y$  - разбиение  $X$  на части

**Ошибка:** объект  $x$  класса  $y$  попал в класс  $s$

$A_s$ ,  $s \neq y$

**Вероятность ошибки:** 
$$P(A_s, y) = \int_{A_s} p(x, y) dx$$

# Байесовский классификатор

про функционал среднего риска:

**Потеря от ошибки:** зададим  $\lambda_{ys} \geq 0$  для всех пар  $(y,s) \in Y \times Y$

**Средний риск:** мат.ожидание потери классификатора

$$R(a) = \sum_{y \in Y} \sum_{s \in Y} \lambda_{ys} P(A_s, y)$$

# Байесовский классификатор

## Теорема про оптимальный байесовский классификатор

пусть заданы:

- априорные вероятности классов  $P(y)$ ,
- плотности их распределений  $p(x|y)$
- $\lambda_{ys} \geq 0$  потери от ошибки

тогда минимум среднего риска  **$R(\mathbf{a})$**  достигается классификатором

$$a(x) = \underset{s \in Y}{\operatorname{argmin}} \sum_{y \in Y} \lambda_{ys} P(y) p(x|y)$$

# Байесовский классификатор

## Теорема про оптимальный байесовский классификатор

пусть заданы:

- априорные вероятности классов  $P(y)$ ,
- плотности их распределений  $p(x|y)$
- $\lambda_{ys} \geq 0$  потери от ошибки

тогда минимум среднего риска  $R(a)$  достигается классификатором

$$a(x) = \underset{s \in Y}{\operatorname{argmin}} \sum_{y \in Y} \lambda_{ys} P(y) p(x|y)$$

### Дополнение:

если  $\lambda_{yy} = 0$  и  $\lambda_{ys} = \lambda_y$  для всех  $y, s \in Y$  то

$$a(x) = \underset{y \in Y}{\operatorname{argmax}} \lambda_y P(y) p(x|y)$$

# Байесовский классификатор

$$a(x) = \underset{y \in Y}{\operatorname{argmax}} \lambda_y P(y) p(x|y)$$

$\lambda_y$  - потеря для объектов  $y$

$P(y)$  - априорная вероятность класса  $y$   
(доля примеров класса  $y$ ,  
пропорция классов должна соответствовать)

$p(x|y)$  - ф-ция правдоподобия класса  $y$  (плотность)

# Байесовский классификатор

## **подходы к оценке плотности распределения:**

- непараметрический
- параметрический
- смеси распределений

# Байесовский классификатор

параметрический подход к оцениванию плотности

$$\hat{p}(x) = \varphi(x, \theta)$$



# Байесовский классификатор

параметрический подход к оценке плотности

$$\hat{p}(x) = \varphi(x, \theta)$$

смеси распределений

$$\hat{p}(x) = \sum_{j=1}^k w_j \varphi_j(x, \theta_j)$$

# Байесовский классификатор

параметрический подход к оцениванию плотности

$$\hat{p}(x) = \varphi(x, \theta)$$

смеси распределений

$$\hat{p}(x) = \sum_{j=1}^k w_j \varphi_j(x, \theta_j)$$

Непараметрический подход к оцениванию плотности

$$\hat{p}(x) = \sum_{j=1}^m \frac{1}{m V(h)} K\left(\frac{\rho(x, x_j)}{h}\right)$$

# Байесовский классификатор

## «наивный Байес»

**допущение:** признаки  $X$  - независимы друг от друга

тогда многомерную плотность  
можно представить как произведение одномерных плотностей

$$p(x|y) = p_1(x_1|y) \dots p_n(x_n|y)$$

# Байесовский классификатор

**непараметрические методы**

**оценка плотности распределения**

дискретный случай (гистограмма) :

$$\hat{p}(x) = \frac{1}{m} \sum_{i=1}^m [x = x_i]$$

*пример:* распределение повторов слов в тексте

# Байесовский классификатор

**непараметрические методы**

**оценка плотности распределения**

непрерывный случай: эмпирическая оценка, окно ширины  $h$   
(доля объектов попавших в отрезок)

$$\hat{p}(x) = \frac{1}{2hm} \sum_{i=1}^m \left[ |x - x_i| < h \right]$$

# Байесовский классификатор

**непараметрические методы**

**оценка плотности распределения**

непрерывный случай: эмпирическая оценка, окно ширины  $h$   
(доля объектов попавших в отрезок)

$$\hat{p}(x) = \frac{1}{2hm} \sum_{i=1}^m \left[ |x - x_i| < h \right]$$

$$\hat{p}(x) = \frac{1}{mh} \sum_{i=1}^m \frac{1}{2} \left[ \frac{|x - x_i|}{h} < 1 \right]$$

# Байесовский классификатор

## оценка плотности Парзона-Розенблата

$$\hat{p}(x) = \frac{1}{mh} \sum_{i=1}^m \frac{1}{2} \left[ \frac{|x - x_i|}{h} < 1 \right]$$

$$\hat{p}(x) = \frac{1}{mh} \sum_{i=1}^m K\left(\frac{x - x_i}{h}\right)$$

$K(r)$  - ядро

чётная ф-ция  $K(r) = K(-r)$

нормированная  $\int K(r) dr = 1$

невозрастающая при  $r > 0$ , неотрицательная ф-ция

# Байесовский классификатор

**оценка Парзона-Розенблата для класса  $y$**

$$\hat{p}(x) = \frac{1}{mh} \sum_{i=1}^m K\left(\frac{x - x_i}{h}\right)$$

$$\hat{p}(x|y) = \frac{1}{l_y V(h)} \sum_{i: y=y_i} K\left(\frac{\rho(x, x_i)}{h}\right)$$

$K(r)$  - ядро

$l_y$  - количество объектов  $y$

$\rho()$  - мера на  $X$

$V(h)$  - нормирующий множитель



# Байесовский классификатор

$$a(x) = \underset{y \in Y}{\operatorname{argmax}} \lambda_y P(y) p(x|y)$$


**метод Парзеновского окна**

$$a(x, X^l, h) = \underset{y \in Y}{\operatorname{argmax}} \lambda_y P(y) \frac{1}{l_y} \sum_{i: y=y_i} K\left(\frac{\rho(x, x_i)}{h}\right)$$

# Байесовский классификатор

**ядро Епанечникова**

$$K(r) = \frac{3}{4}(1 - r^2); |r| \leq 1$$



# Байесовский классификатор

## **выбор оптимального размера окна h**

метод скользящего контроля (Leave One Out, LOO)

параметр h выбираем перебором

проверяем суммарную ошибку на учебном множестве

из учебного набора удаляется текущий (проверяемый) пример.

$$LOO(h, X) = \sum_{i=1}^l [a(x_i, \{X \setminus x_i\}, h) \neq y_i] \rightarrow \min_h$$

# Байесовский классификатор

**оценка плотности - параметрический подход**

$$\hat{p}(x) = \varphi(x, \theta)$$

# Байесовский классификатор

**оценка плотности - параметрический подход**

$$\hat{p}(x) = \varphi(x, \theta)$$

принцип максимума правдоподобия

$$L(\theta, X) = \sum_{i=1}^m \ln \varphi(x_i, \theta) \rightarrow \max_{\theta}$$

# Байесовский классификатор

**оценка плотности - параметрический подход**

$$\hat{p}(x) = \varphi(x, \theta)$$

принцип максимума правдоподобия

$$L(\theta, X) = \sum_{i=1}^m \ln \varphi(x_i, \theta) \rightarrow \max_{\theta}$$


условие оптимума

$$\frac{\partial}{\partial \theta} L(\theta, X) = \sum_{i=1}^m \frac{\partial}{\partial \theta} \ln \varphi(x_i, \theta) = 0$$

# Байесовский классификатор

**допущение:** классы имеют n-мерную нормальную плотность

$$p(x|y) = \frac{\exp\left(-\frac{1}{2}(x-\mu_y)^T \Sigma_y^{-1}(x-\mu_y)\right)}{\sqrt{(2\pi)^n \det \Sigma_y}}; y \in Y$$



# Байесовский классификатор

**Теорема:** параметры оценки максимального правдоподобия для  $n$ -мерных гауссовских плотностей классов  $y$  имеют следующий вид

$$\hat{\mu}_y = \frac{1}{l_y} \sum_{i: y=y_i} x_i \quad \hat{\Sigma}_y = \frac{1}{l_y} \sum_{i: y=y_i} (x_i - \hat{\mu}_y)(x_i - \hat{\mu}_y)^T$$



# Байесовский классификатор

**Теорема:** параметры оценки максимального правдоподобия для  $n$ -мерных гауссовских плотностей классов  $y$  имеют следующий вид

$$\hat{\mu}_y = \frac{1}{l_y} \sum_{i: y=y_i} x_i \quad \hat{\Sigma}_y = \frac{1}{l_y} \sum_{i: y=y_i} (x_i - \hat{\mu}_y)(x_i - \hat{\mu}_y)^T$$

**классификатор:** квадратичный дискриминант

$$a(x) = \underset{y \in Y}{\operatorname{argmax}} \left( \ln(\lambda_y P_y) - (x - \hat{\mu}_y)^T \hat{\Sigma}_y^{-1} (x - \hat{\mu}_y) - \frac{1}{2} \ln(\det \hat{\Sigma}_y) \right)$$

# Байесовский классификатор

## Дополнение:

если матрицы ковариаций классов равны  
то параметры оценки плотности имеют следующий вид

$$\hat{\mu}_y = \frac{1}{l_y} \sum_{i: y=y_i} x_i \quad \hat{\Sigma} = \frac{1}{l} \sum_{i=1}^l (x_i - \hat{\mu}_{y_i})(x_i - \hat{\mu}_{y_i})^T$$

# Байесовский классификатор

## Дополнение:

если матрицы ковариаций классов равны  
то параметры оценки плотности имеют следующий вид

$$\hat{\mu}_y = \frac{1}{l_y} \sum_{i: y=y_i} x_i \quad \hat{\Sigma} = \frac{1}{l} \sum_{i=1}^l (x_i - \hat{\mu}_{y_i})(x_i - \hat{\mu}_{y_i})^T$$

**классификатор:** линейный дискриминант Фишера

$$a(x) = \underset{y \in Y}{\operatorname{argmax}} \left( \ln(\lambda_y P_y) - \frac{1}{2} \hat{\mu}_y^T \hat{\Sigma}^{-1} \hat{\mu}_y + x^T \hat{\Sigma}^{-1} \hat{\mu}_y \right)$$

# Классификатор: оценка результата 1

**разделяем набор данных**

- учебный
- тестовый


**недообучение** (underfitting)

большая ошибка на учебном наборе

**переобучение** (overfitting)

малая ошибка на учебном наборе

большая ошибка на тестовом наборе



# Классификатор: оценка результата 2

## **метрики качества на тестовом наборе**

- погрешность (accuracy)
- матрица ошибок ( confusion matrix )
- точность (precision)
- полнота (recall)
- F-мера
- ROC/AUC

# Классификатор: оценка результата 3


## **погрешность (accuracy)**

правильные ответы / всего примеров

оценка для сбалансированного набора, т.е.  
количество примеров в классах +- одинаковое

# Классификатор: оценка результата 8

матрица ошибок ( confusion matrix )



два класса — четыре группы

- TP истинно положительные
- TN истинно отрицательные
- FP ложно положительные
- FN ложно отрицательные

# Классификатор: оценка результата 9

## точность (precision)

$$TP / ( TP + FP )$$

(метрики для отдельного класса)

доля объектов действительно принадлежащих данному классу относительно всех объектов, которые классификатор отнес к этому классу

## полнота (recall)

$$TP / ( TP + FN )$$

доля объектов, найденных классификатором, относительно всех объектов этого класса

## F-мера

$$( precision * recall ) / ( precision + recall )$$

усреднение точности и полноты




# Классификатор: оценка результата 10

**Пример** *classification\_report*

	precision	recall	f1-score	support
0	0.90	0.90	0.90	2835
1	0.91	0.90	0.91	2927
avg / total	0.90	0.90	0.90	5762

# Классификатор: оценка результата 11

*ROC - receiver operating characteristic,  
рабочая характеристика приёмника*



*AUC - area under ROC curve,  
площадь под ROC-кривой  
характеристика качества классификации*

$$\text{TPR} = \text{TP} / (\text{TP} + \text{FN})$$

полнота(recall), доля объектов, найденных классификатором, относительно всех объектов этого класса

$$\text{FPR} = \text{FP} / (\text{FP} + \text{TN})$$

доля объектов negative класса алгоритм предсказал неверно

**ROC** - показывает зависимость полноты **TPR**

от доли ложно-негативных **FPR** при изменении порога сора

# Классификатор: литература

К.В. Воронцов Байесовская теория классификации и методы восстановления плотности. - Курс "Машинное обучение" ШАД Яндекс 2014

Борисов Е.С. Байесовский классификатор.  
<http://mechanoid.kiev.ua/ml-bayes.html>

git clone [https://github.com/mechanoid5/ml\\_lectorium.git](https://github.com/mechanoid5/ml_lectorium.git)

Классификатор: почти последний слайд...



**Вопросы ?**

# Классификатор: практика

## источники данных для экспериментов



`sklearn.datasets`

UCI Repository

kaggle

